基于视觉代理与描述融合的零样本组合式图像检索改进

本科毕业设计答辩

杨昊明

同济大学电子与信息工程学院
计算机科学与技术专业

2026 年 5 月

指导教师：（填写指导教师）

任务形式：给定一张**参考图像** I_r 和一段**修改文本** t，在图库 $\mathcal{G}$ 中检索符合修改意图的目标图像。

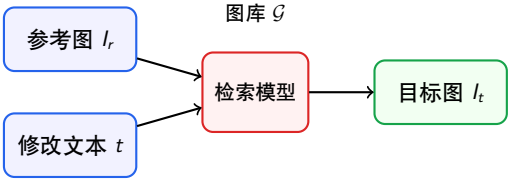

典型场景：

- 服饰检索："同款但颜色改为红色的裙子"
- 场景检索："保留原场景，把猫换成狗"

零样本设定（ZS-CIR）：

- 不依赖目标数据集训练
- 仅依靠预训练模型泛化
- 更贴近真实应用

OSrCIR (CVPR 2025 Highlight)：首个单阶段反思推理的零样本组合检索方法

参考图 + 文本 → MLLM 推理 → 目标描述 D_1 → CLIP → 检索结果

三个关键问题：

- ✗ **缺乏视觉验证**：只调用一次 MLLM，若描述偏差则无法纠正
- ✗ **单一路径脆弱**：CLIP 对文本敏感，检索全部依赖一条描述
- ✗ **难以利用 AI 生成图像**：直接使用会引入幻觉反而退化

核心研究问题

如何将 AI 生成图像作为“**可用但不可信**”的辅助信号纳入检索流程，同时避免其成为新的误差来源？

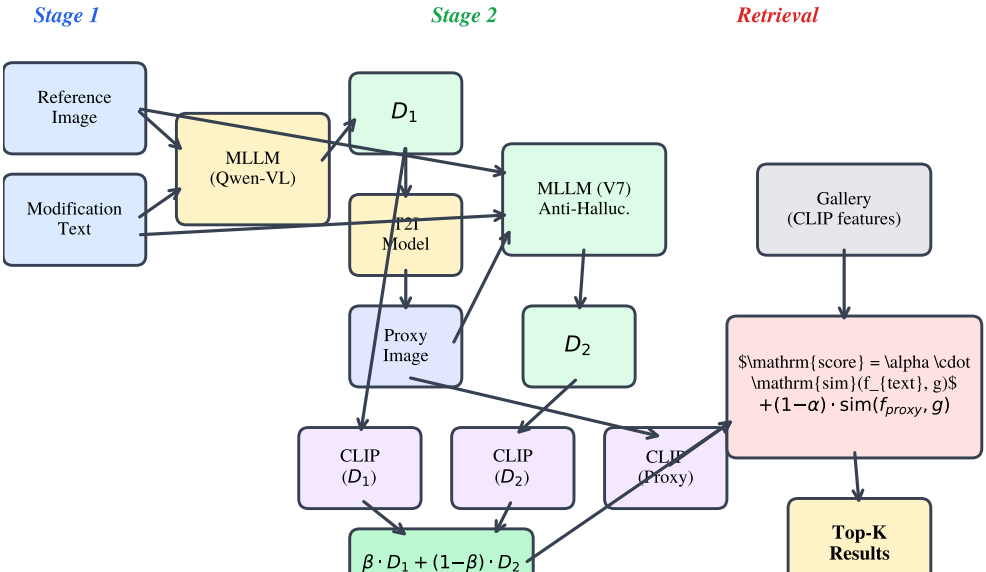
Stage 1
Stage 2
Retrieval
Reference Image
Modification Text
MLLM (Qwen-VL)
D_1
T21 Model
Proxy Image
MLLM (V7) Anti-Halluc.
D_2
Gallery (CLIP features)
$\mathrm{score} = \alpha \cdot \mathrm{sim}(f_{text}, g)$
$+(1-\alpha) \cdot \mathrm{sim}(f_{proxy}, g)$
CLIP (D_1)
CLIP (D_2)
CLIP (Proxy)
$\beta \cdot D_1 + (1-\beta) \cdot D_2$
Top-K Results

核心思想：把文本推理结果投射到图像空间，获得可视化的中间产物。

代理图的两类作用：

- **检索信号**：与文本特征互补，提供图像空间线索
- **诊断参照**：辅助第二轮判断 D_1 是否准确表达修改意图

初步验证（FIQ dress 50 样本）：

方法	R@10
Baseline (纯 D_1)	18.0
+ 后融合代理图	**26.0** +8.0

实现细节：

- 文生图模型：MiniMax image-01
- 每条 D_1 生成一张代理图
- 代理图用 CLIP ViT-L/14 编码
- 与 Gallery 图像在相同特征空间中计算相似度

关键挑战

代理图虽然有用，但 AI 生成**必然包含幻觉**，需要专门约束其使用方式。

核心矛盾：代理图既是有用的参照，又是幻觉的来源。

Prompt 迭代历程（CIRR R@10, 200 样本）：

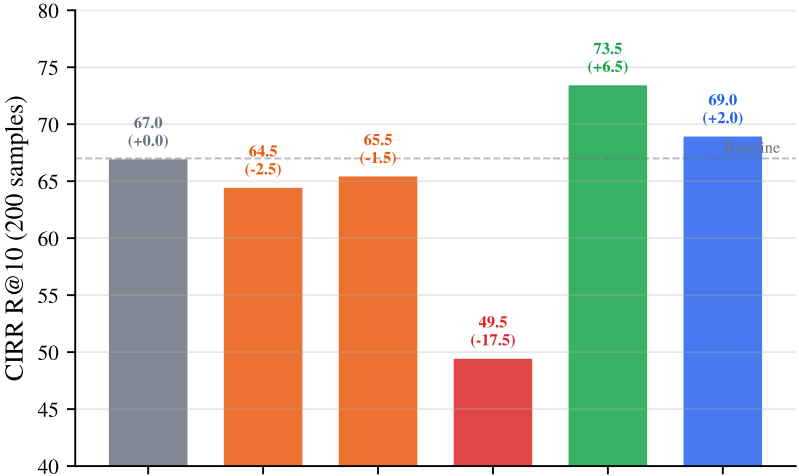

V7 核心设计（3 条原则）：

1. 明确告诉模型："代理图是 *AI* 生成的，可能含有错误与幻觉"
2. 限定代理图唯一用途：**检查修改是否被正确应用**，不可复制其视觉细节
3. 强制输出简短描述，只保留与检索最相关的核心属性

任务范式的根本转变：

$$\text{“重新描写目标图像”} \Longrightarrow \text{“在 } D_1 \text{ 基础上做}\textbf{最小必要修正}\text{”}$$

核心洞察

信息过多反而有害（V6 失败）；**限制信息来源比增加信息更重要**（V7 突破）。这是整个 prompt 工程中最关键的认识。

问题：V7 在 CIRR 上+6.5，但在 FIQ shirt 上−4.0 ——直接替换 D_1 不稳定。

解决方案：CLIP 特征空间加权融合（而非替换）

文本融合公式

$$\mathbf{f}_{\text{text}} = \text{normalize}\big(\beta \cdot \text{CLIP}(D_1) + (1-\beta) \cdot \text{CLIP}(D_2)\big)$$

三路融合得分

$$\text{score}(I_c) = \alpha \cdot \text{sim}(\mathbf{f}_{\text{text}}, \text{CLIP}(I_c))$$
$$+(1-\alpha) \cdot \text{sim}(\text{CLIP}(P), \text{CLIP}(I_c))$$

默认参数选择：

- $\beta = 0.7$：D_1 占 70%（兜底）+ D_2 占 30%（修正）
- $\alpha = 0.9$：文本占 90%（主导）+ 代理图占 10%（辅助）

设计哲学：

保守融合，稳中求进
极端提升 ⇒ 全局稳定

效果：V7+Ensemble 在 CIRR +2.0、shirt +0.5，**所有子集统一正向**。

评估基准（9 个子任务）：

- **FashionIQ**：dress / shirt / toptee（服饰）
- **CIRCO**：开放域，123K 图库
- **CIRR**：自然场景，2297 图库
- **GeneCIS**：ch_obj / fo_obj / ch_attr / fo_attr（细粒度）

模型配置：

- MLLM：Qwen-VL-Max（替代原论文 GPT-4o）
- 文生图：MiniMax image-01
- 视觉编码：CLIP ViT-L/14（与原论文一致）
- 默认参数：$\beta = 0.7$, $\alpha = 0.9$

评估指标：

- FashionIQ / CIRR / GeneCIS：Recall@K
- CIRCO：mAP@K（多目标设置）

关于基线复现：

- 原论文 GPT-4o *vs* 本文 Qwen-VL-Max
- FashionIQ dress R@10: 29.70 $\rightarrow$ 15.80
- **所有改进在同一基线上比较，公平**

花费：MLLM + T2I API 约 **¥140**

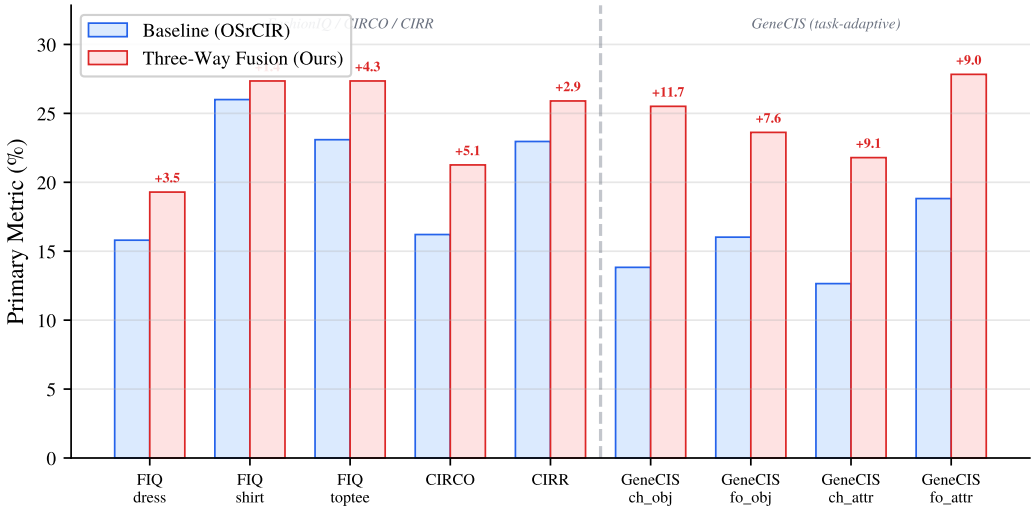

35 项评估指标全部正向，0 退化。左侧 5 个用默认参数，右侧 4 个 GeneCIS 用

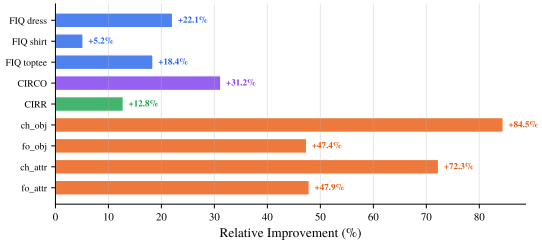

数据集	Base.	Ours	提升
FIQ dress	15.80	19.29	+22.1%
FIQ shirt	26.00	27.35	+5.2%
FIQ toptee	23.09	27.35	+18.4%
CIRCO	16.21	21.26	+31.2%
CIRR	22.96	25.90	+12.8%
Gen ch_obj	13.83	25.51	+84.5%
Gen fo_obj	16.02	23.62	+47.4%
Gen ch_attr	12.65	21.79	+72.3%
Gen fo_attr	18.82	27.83	+47.9%

亮点：GeneCIS 最大**+84.5%**；CIRCO **+31.2%**；FIQ shirt 最保守但仍**+5.2%**

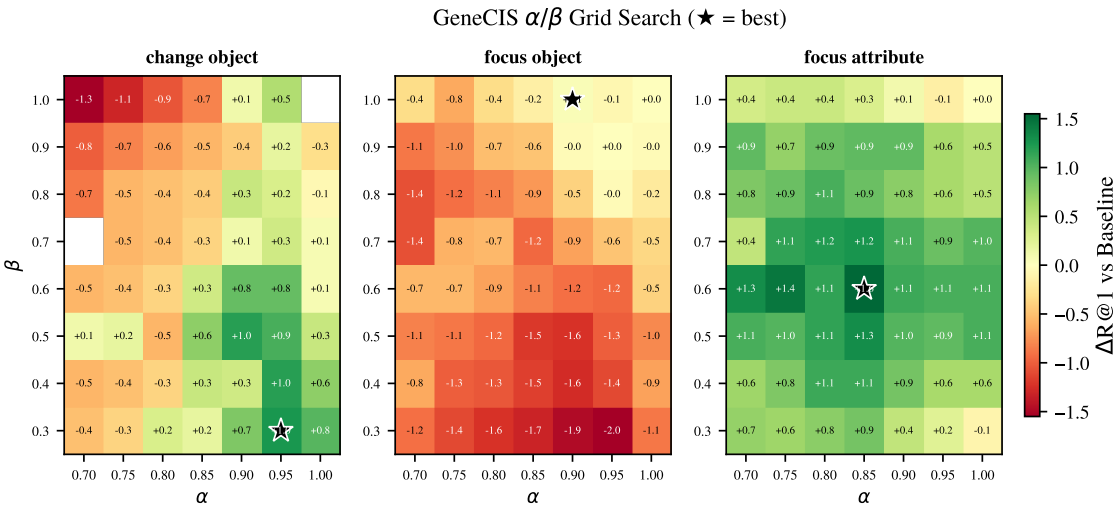
GeneCIS α/β Grid Search (★ = best)
change object
focus object
focus attribute
β
α
ΔR@1 vs Baseline
1.0 -1.3 -1.1 -0.9 -0.7 +0.1 +0.5
0.9 -0.8 -0.7 -0.6 -0.5 -0.4 +0.2 -0.3
0.8 -0.7 -0.5 -0.4 -0.4 +0.3 +0.2 -0.1
0.7 -0.5 -0.4 -0.3 +0.1 +0.3 +0.1
0.6 -0.5 -0.4 -0.3 +0.3 +0.8 +0.8 +0.1
0.5 +0.1 +0.2 -0.5 +0.6 +1.0 +0.9 +0.3
0.4 -0.5 -0.4 -0.3 +0.3 +0.3 +1.0 +0.6
0.3 -0.4 -0.3 +0.2 +0.2 +0.7 +0.8
1.0 -0.4 -0.8 -0.4 -0.2 -0.1 +0.0
0.9 -1.1 -1.0 -0.7 -0.6 -0.0 +0.0 -0.0
0.8 -1.4 -1.2 -1.1 -0.9 -0.5 -0.0 -0.2
0.7 -1.4 -0.8 -0.7 -1.2 -0.9 -0.6 -0.5
0.6 -0.7 -0.7 -0.9 -1.1 -1.2 -1.2 -0.5
0.5 -1.1 -1.1 -1.2 -1.5 -1.6 -1.3 -1.0
0.4 -0.8 -1.3 -1.3 -1.5 -1.6 -1.4 -0.9
0.3 -1.2 -1.4 -1.6 -1.7 -1.9 -2.0 -1.1
1.0 +0.4 +0.4 +0.4 +0.3 +0.1 -0.1 +0.0
0.9 +0.9 +0.7 +0.9 +0.9 +0.9 +0.6 +0.5
0.8 +0.8 +0.9 +1.1 +0.9 +0.8 +0.6 +0.5
0.7 +0.4 +1.1 +1.2 +1.2 +1.1 +0.9 +1.0
0.6 +1.3 +1.4 +1.1 +1.1 +1.1 +1.1
0.5 +1.1 +1.0 +1.1 +1.3 +1.0 +0.9 +1.1
0.4 +0.6 +0.8 +1.1 +1.1 +0.9 +0.6 +0.6
0.3 +0.7 +0.6 +0.8 +0.9 +0.4 +0.2 -0.1
0.70 0.75 0.80 0.85 0.90 0.95 1.00
1.5 1.0 0.5 0.0 −0.5 −1.0 −1.5

关键发现:

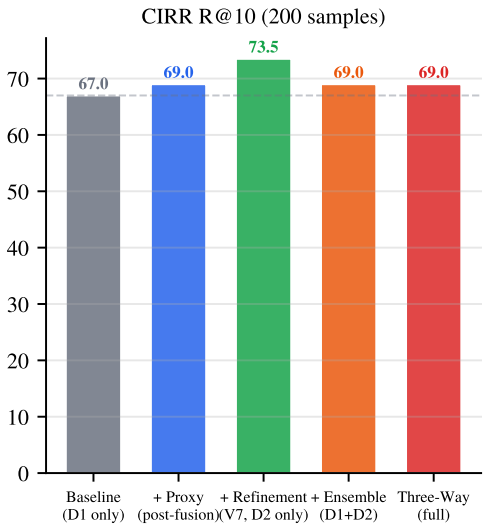

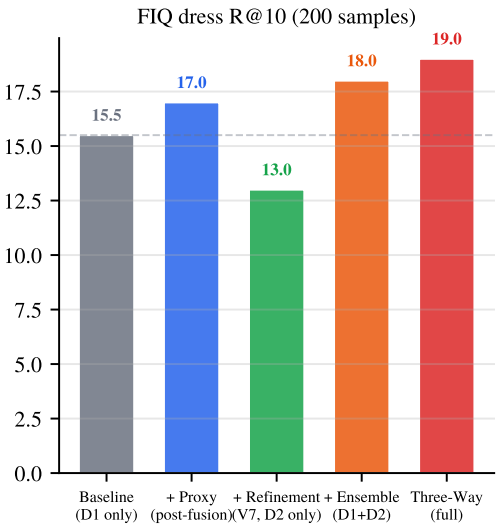

核心洞察：不同数据集上模块最优配置截然相反

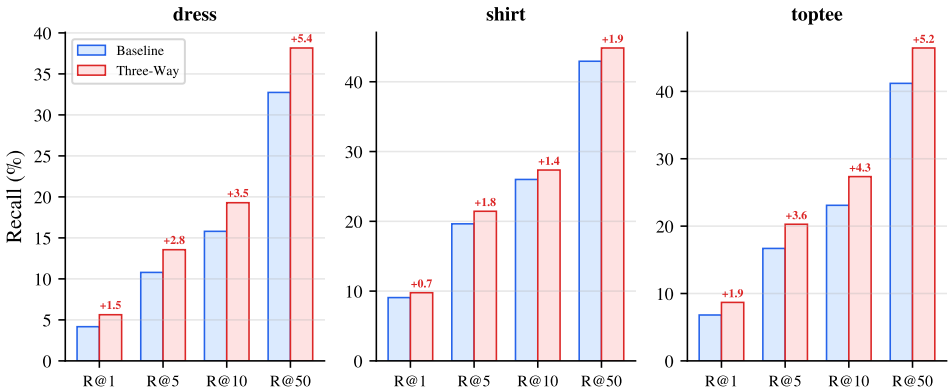

观察：

- **dress**：R@50 提升最大（**+5.4**），颜色/款式变化敏感
- **shirt**：提升最保守（R@10 **+1.4**），纹理细节难以捕获
- **toptee**：R@10 **+4.3**，介于两者之间

本文主要贡献：

- ✓ 提出**视觉代理机制**：首次将文生图模型引入零样本组合检索，提供图像空间辅助信号
- ✓ 设计 **V7 反幻觉提示词**：限定代理图的诊断角色，避免幻觉污染
- ✓ 构建**三路融合框架**：在 CLIP 空间统一三类信号，兼顾稳健性与性能
- ✓ 针对 **GeneCIS 任务特性**提出专用 prompt + task-adaptive 参数

实验验证：

9 个数据集 × 35 项指标 = **35 项全部提升**，**0 退化**

证明了在零样本组合检索中，**“多信号融合 + 幻觉约束”**比“单点推理优化”更有价值。

短期改进方向：

- **自适应参数预测**：根据 query 特征动态选择 α/β
- **多代理图策略**：生成多张代理图投票，减少单图噪声
- **更强 MLLM**：用 GPT-4o / Gemini 2.0 重新验证上限

长期扩展方向：

- **有监督 CIR**：迁移到训练数据充足场景
- **交互式检索**：支持多轮对话式精炼
- **视频组合检索**：扩展到时序维度

感谢各位老师！

欢迎批评指正

Q：本文 Baseline 远低于原论文报告值，结果是否可信？

原因分析：

- 原论文使用 GPT-4o，本文因 API 可用性改用 Qwen-VL-Max
- Qwen-VL-Max 在服饰细粒度描述上不及 GPT-4o（FashionIQ 差约 14pp）
- 但 GeneCIS focus_object 上 Qwen-VL 反而略胜 GPT-4o（16.02 vs 15.00）

对公平性的影响：无

- 所有改进均在**同一 Baseline** 上对比，相对提升可比
- 使用 Qwen-VL-Max 只降低绝对值，不改变方法有效性
- 三路融合的核心逻辑（代理 + 反幻觉 + 融合）是模型无关的

Q：为什么选 $\beta = 0.7$、$\alpha = 0.9$？是否经过调优？

$\beta = 0.7$ **的依据**：

- D_1 信息完整度 $> D_2$（V7 prompt 要求简短）
- 若 $\beta < 0.5$，FIQ shirt 会因 D_2 过激精炼而退化
- FashionIQ + CIRR 联合调参的折中点

$\alpha = 0.9$ **的依据**：

- 代理图含 AI 幻觉，不宜主导检索（$\alpha < 0.5$ 时 CIRCO 明显退化）
- 10% 权重足以提供互补信号，不导致场景偏移

GeneCIS 为何需要 task-adaptive：

- 修改文本仅 1–2 词，V7 的 “描述不超过修改文本” 限制使 D_2 退化
- 每个 query 仅 ∼14 张候选图，代理图场景偏好影响被放大
- 网格搜索：各子集最优参数 β 从 0.3 到 1.0，差异显著