同济大学 2026 届本科毕业设计答辩

基于视觉代理与描述融合的零样本组合式图像检索改进

— 对 CVPR 2025 Highlight OSrCIR 的三路融合改进 —

答辩人

杨 浩 铭

指导教师

XXX 教授

专业 / 学院

计算机科学与技术 · 电子与信息工程学院

关键词： 零样本组合式图像检索 · 多模态大模型 · 视觉代理 · 描述融合 · CLIP

目　录

Contents

01 **研究背景与意义**

零样本组合式图像检索（ZS-CIR）与 OSrCIR 基线

02 **研究内容与问题**

基线瓶颈：描述缺乏视觉验证 / MLLM 易幻觉

03 **方法：三路融合**

Visual Proxy + V7 反幻觉 CoT + Description Ensemble

04 **实验与结果**

9 个标准数据集全量实验，35/35 指标全部提升

05 **消融与分析**

α/β 网格搜索、prompt 迭代、跨数据集泛化

06 **总结与展望**

工作贡献、局限性、后续可拓展方向

任务定义

给定（参考图，修改文本）二元组
—— 修改文本描述："把裙子换成黑色短款"
在大图库（万～十万级）中检索符合描述的目标图像。

约束：零样本 (Zero-Shot)
—— 不允许在下游数据集做任何训练或微调

应用场景

- 电商服装检索：以图 + 文细化筛选 (Amazon，阿里)
- 内容创作素材库：基于已有图修改意图找素材
- 安防 / 医疗：带条件修改的相似案例匹配
- 通用基础模型 (CLIP / MLLM) 下游通用能力评测

基线论文：OSrCIR (CVPR 2025 Highlight)

arXiv 2412.11077 · 2024.12 · One-Stage reflective CIR

核心流程（单轮 CoT 推理）

① 参考图 + 修改文本
↓ (MLLM with CoT prompt)
② 目标描述 D（纯文本）
↓ (CLIP ViT-L/14)
③ 文本特征 → 与图库检索

主要贡献

- 将 MLLM 作为"反射式"理解器引入 ZS-CIR
- 零训练，纯 prompt + CLIP 对齐即可刷新 SOTA
- 统一覆盖 FashionIQ / CIRCO / CIRR / GeneCIS

02 基线瓶颈与改进切入点

单轮推理的结构性缺陷 · MLLM 幻觉风险

难点 1 · 缺乏视觉验证信号

MLLM 仅凭参考图 + 文本做一次推理输出 D1,
没有图像侧 (image space) 的反馈闭环。
一旦遗漏关键修改，错误会直接传导到检索。

难点 2 · MLLM 幻觉风险高

直接在 prompt 中让 MLLM 自由精炼描述，
容易引入代理图中的 AI 虚构细节（背景 / 材质）
导致描述膨胀 ~ 1.9×, CLIP 空间反而远离目标。

难点 3 · 跨任务策略不统一

FashionIQ / CIRCO / CIRR / GeneCIS 任务特性
差异大（时尚属性 / 开放场景 / 细粒度改动),
单一 prompt 策略难以在 9 个子集全面正向。

改进切入点（与老师多轮讨论后确定）

① 引入 文生图代理 (Visual Proxy)，为纯文本推理补上 “图像级校验”
② 设计 V7 反幻觉 CoT: 代理图仅作 “诊断”，禁止写入虚构细节
③ 在 CLIP 特征空间做 Description Ensemble, 让 D1 兜底，D2 增量修正 —— 保证不退化

03 方法 · 三路融合总体框架

Visual Proxy + V7 Anti-Hallucination CoT + Description Ensemble

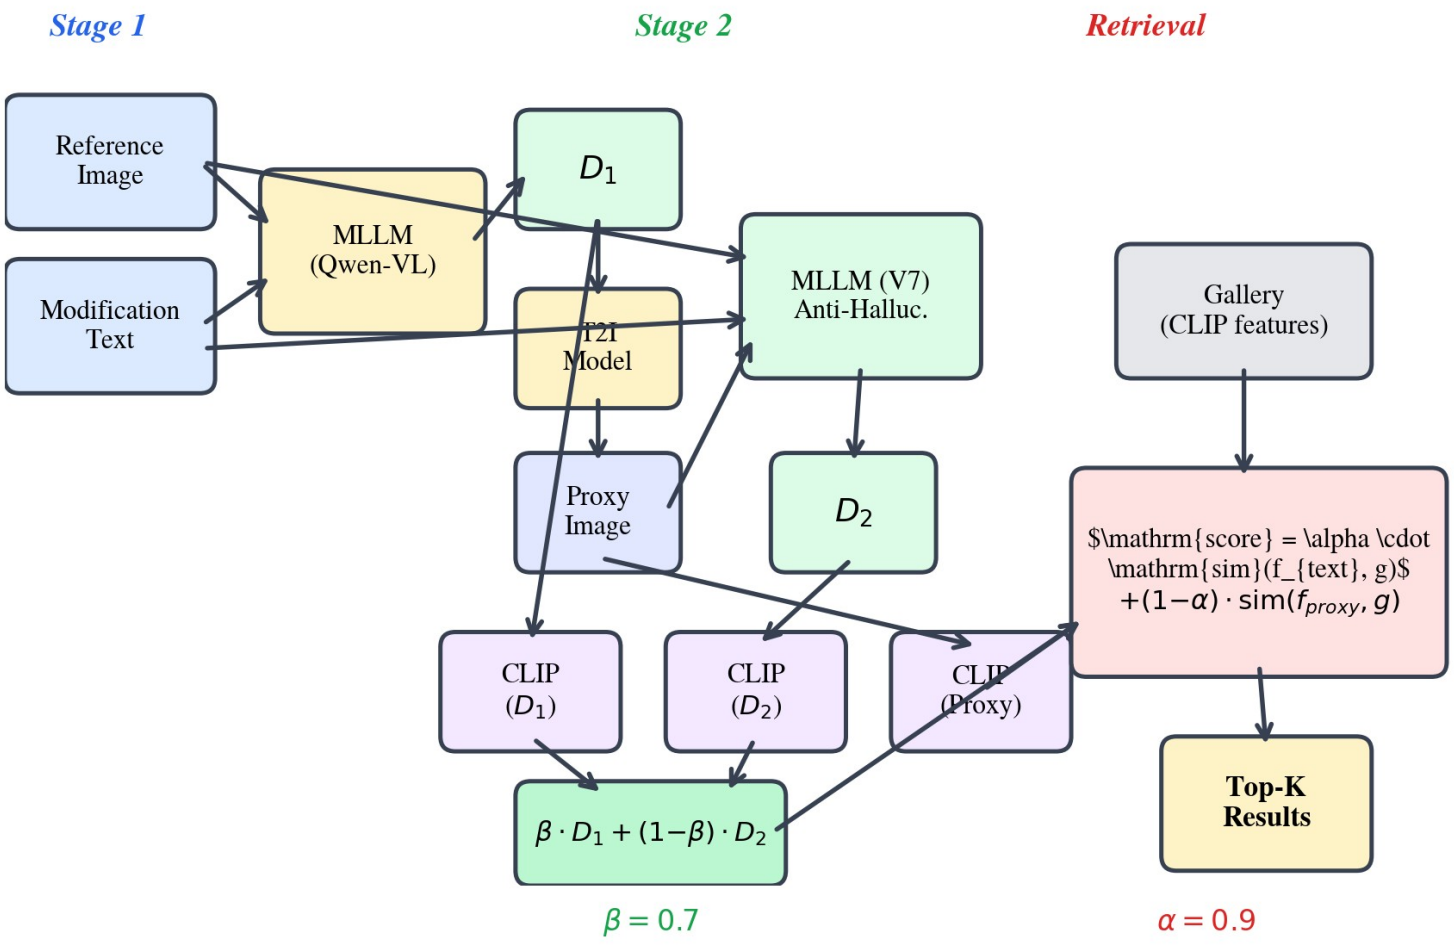

检索公式

```
f_text =
  norm( β · CLIP(D₁) +
        (1−β) · CLIP(D₂) )

score =
  α · sim(f_text, g)
 + (1−α) · sim(CLIP(proxy), g)
```

默认参数

- $\beta = 0.7$ (D_1 权重)
- $\alpha = 0.9$ (文本信号主导)
- CLIP: ViT-L/14
- MLLM: Qwen-VL-Max
- T2I: MiniMax image-01

整体特点

- 零训练，纯推理
- 三信号互补
- D_1 兜底防退化

03.1 创新点 ① · Visual Proxy

将文本推理 “画” 出来，为检索提供图像空间信号

动机

原方法全程在文本空间操作，
描述一旦偏差，下游 CLIP 检索将
直接失败且无可恢复路径.

解决：让 MLLM 的初始描述 D_1
经 T2I 模型 (MiniMax image-01)
再生成一张代理图 proxy,
然后把代理图作为图库检索时的
“第二路” 图像查询，与文本信号互补.

两种使用方式（消融）

- Plan A — 后融合：在检索得分上做加权
- Plan B — 前融合：把 proxy 喂回 MLLM 做二轮精炼
  → 最终方案 两者结合 (A 做检索 · B 做精炼)

FashionIQ dress 子集 (50 样本) R@10

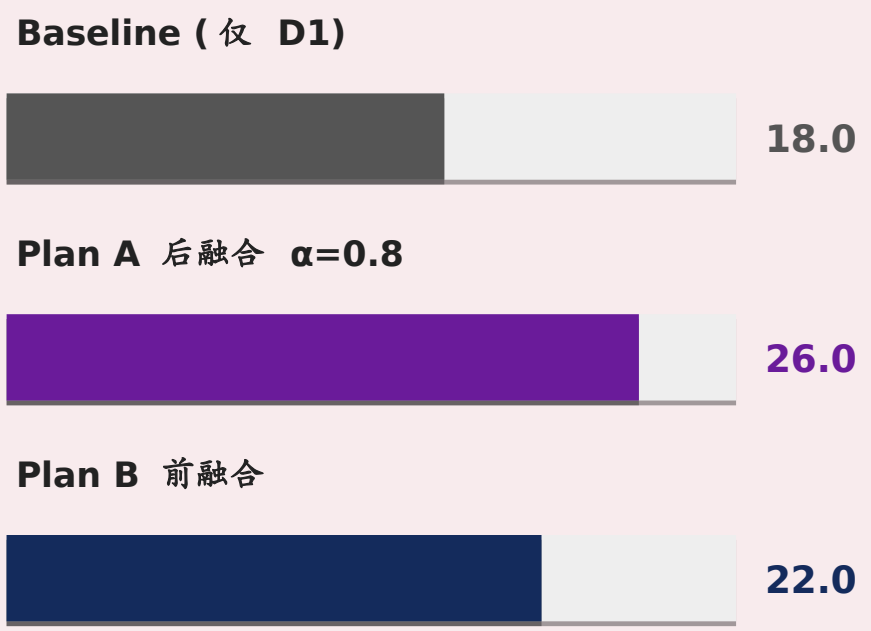

→ 两种方式均显著提升 baseline
→ 验证了 proxy 确实携带可用的图像级信息

03.2 创新点 ② · V7 反幻觉 CoT Prompt

Prompt 迭代 4 轮，终于解决 “代理图是参照又是幻觉源” 的矛盾

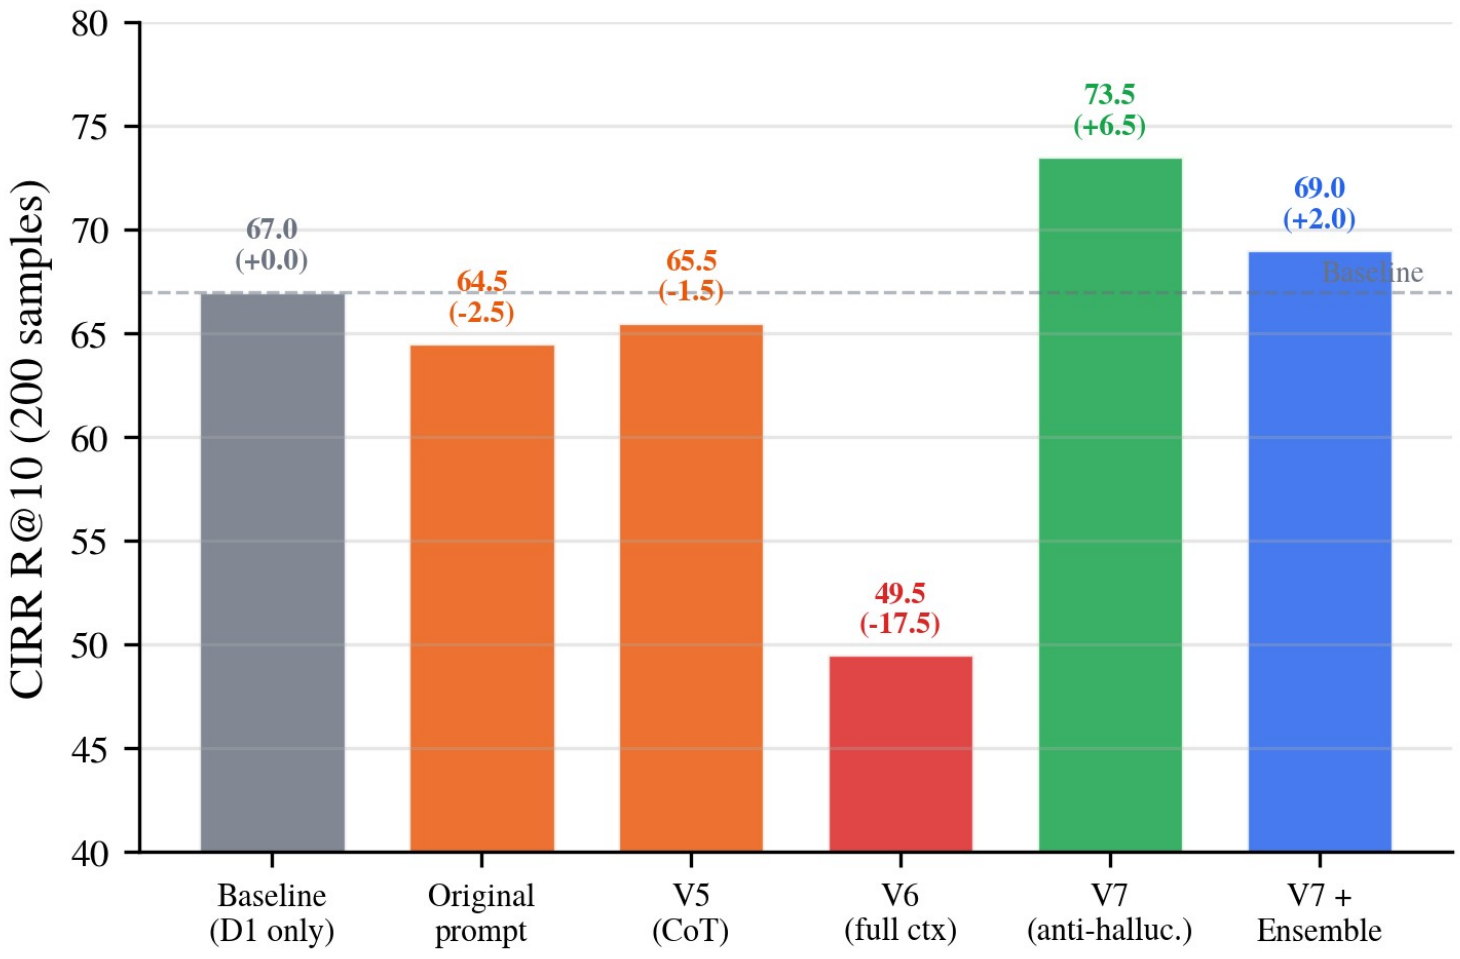

V7 的三个关键设计

① 代理图 AI 生成

prompt 中显式声明：代理图含幻觉细节
禁止写入代理图中新增物体 / 背景

② 代理图仅做 “诊断”

唯一用途：检查颜色 / 物体 / 属性
是否已按修改文本改变

③ 强制短描述

输出长度 ≤ 修改文本长度
避免描述膨胀导致 CLIP 漂移

CIRR R@10: 67.0 → 73.5 (+6.5)

03.3 创新点 ③ · Description Ensemble

用 D_1 兜底 · 用 D_2 增量修正 · 保证不退化

为什么需要 Ensemble ?

V7 在 CIRR 提升 +6.5, 但在 FashionIQ shirt 反而 − 4.0
原因：单一 prompt 策略存在固有矛盾：

- 激进精炼 → 修正偏差但可能丢失细节
- 保守精炼 → 保留细节但改善有限

→ 根本问题："全或无" 替换 $D_1 \to D_2$ 粒度太粗

解决方案

$$f_text = normalize(\beta \cdot CLIP(D_1) + (1-\beta) \cdot CLIP(D_2))$$

$$\beta = 0.7 \quad (D_1 \text{ 特征 } 70\% \cdot D_2 \text{ 特征 } 30\%)$$

→ 在 CLIP 特征空间做 weighted-sum 而非硬替换
→ 即使 D_2 在某些样本上差，D_1 的信号仍占主导
→ 实现所有子集的 统一正向提升

关键对比 (R@10)

方法	CIRR	shirt	是否全正向
Baseline (仅 D1)	67.0	30.0	—
V7 (D2 替换 D1)	73.5 (+6.5)	26.0 (−4.0)	否
V7 + Ensemble β=0.7	69.0 (+2.0)	30.5 (+0.5)	是

Ensemble 放弃 V7 在 CIRR 上的极端提升，
换取所有子集的统一正向提升 ——
这才是 "工程可用" 的改进方案

04.1 实验设置

9 个标准基准 · 统一评估口径

数据集 (9 个基准)

FashionIQ
dress 1918 · shirt 1996 · toptee 1923
指标：R@10 / R@50

CIRCO
220 queries · 123K 图库 (COCO 扩展)
指标：mAP@5/10/25/50

CIRR
4181 queries · 2297 图库
指标：R@1/5/10/50 · R_sub

GeneCIS
change/focus × object/attribute (4 子集)
指标：R@1/2/3

技术栈与资源

MLLM Qwen-VL-Max (阿里云 DashScope)
原论文 GPT-4o → 因 API 可用性替换
差异仅影响 baseline 绝对值，不影响相对改进

T2I 模型 MiniMax image-01
初始描述 D_1 → 代理图 proxy · 512×512

视觉编码器 CLIP ViT-L/14 (与论文一致)
同时编码 D_1 / D_2 / proxy / gallery

计算资源 Linux 3.6GB RAM + Windows RTX 4060 8GB
MLLM / T2I 云端 API · CLIP 特征本地 GPU 计算

04.2 主结果 · 9 个数据集全量实验

35 / 35 指标全部提升 · 9 / 9 主指标全部正向

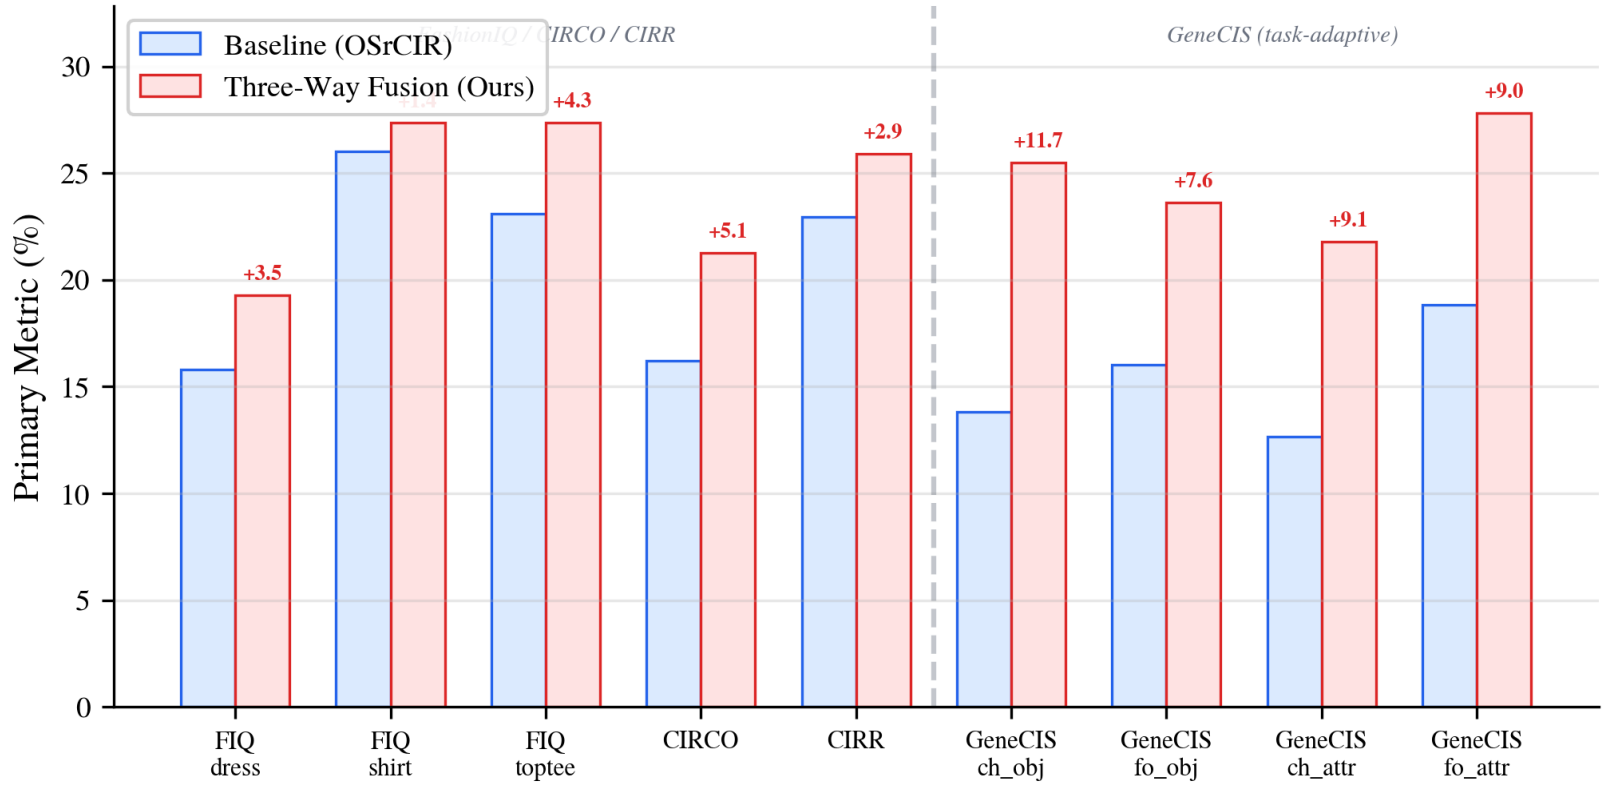

关键提升（主指标）

FIQ dress R@10	+3.49	+22.1%
FIQ toptee R@10	+4.26	+18.4%
CIRCO mAP@10	+5.05	+31.2%
CIRR R@1	+2.94	+12.8%
GeneCIS ch_obj R@1	+11.68	+84.5%
GeneCIS ch_attr R@1	+9.14	+72.3%
GeneCIS fo_attr R@1	+9.01	+47.9%

- ✓ **35 / 35** 指标全部提升
- ✓ 无持平、无微降
- ✓ **GeneCIS** 相对提升 **47%~85%**
- ✓ 零训练 · 纯推理改进

04.3 FashionIQ 细化结果

服装时尚属性 · 3 子集 12 指标全部提升

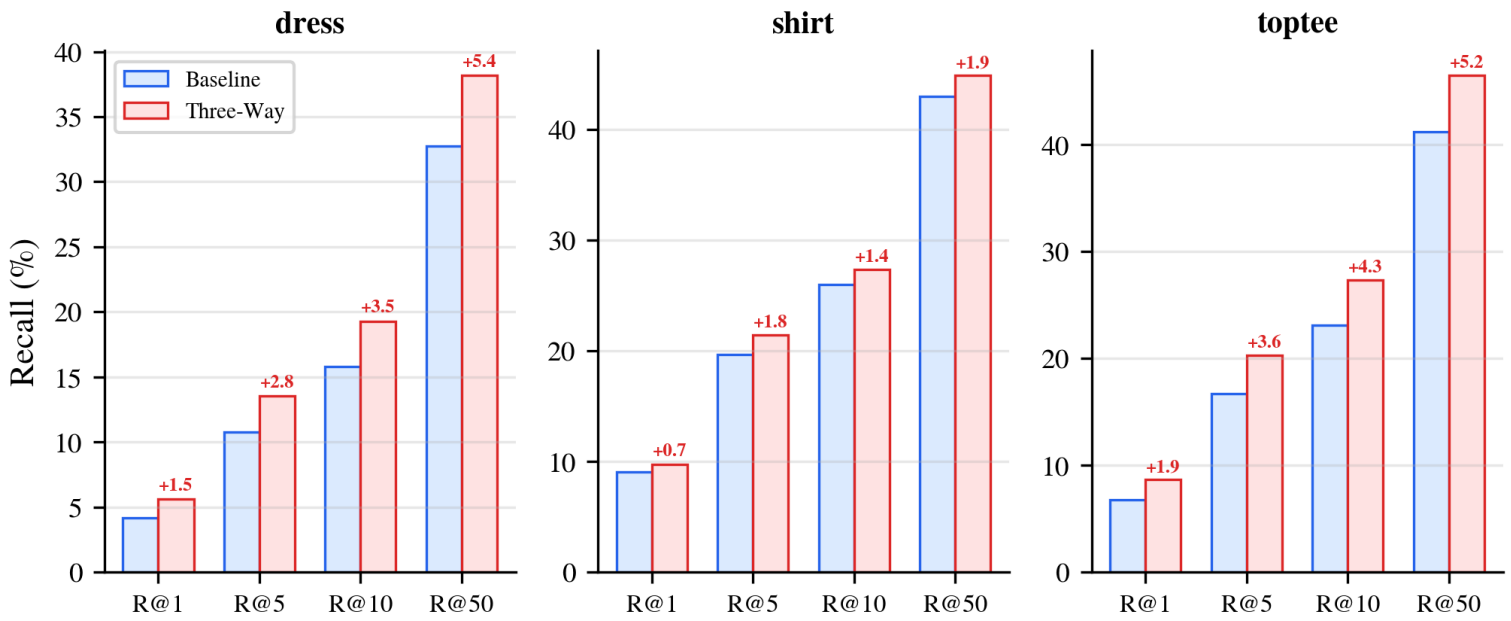

关键观察

dress 子集

R@10 +3.49 (22.1%)
R@50 +5.42 (16.6%)
→ proxy 对长描述效果显著

shirt 子集

R@10 +1.35 (5.2%)
→ V7 短描述策略原本有退化风险
→ Ensemble 成功 “兜底”

toptee 子集

R@10 +4.26 (18.4%)
R@50 +5.25 (12.7%)
→ 改进幅度仅次于 dress

与原论文差距主要来自 MLLM 替换，不影响改进有效性

05.1 消融 · α/β 网格搜索

GeneCIS 各子集最优参数差异显著 · task-adaptive 有价值

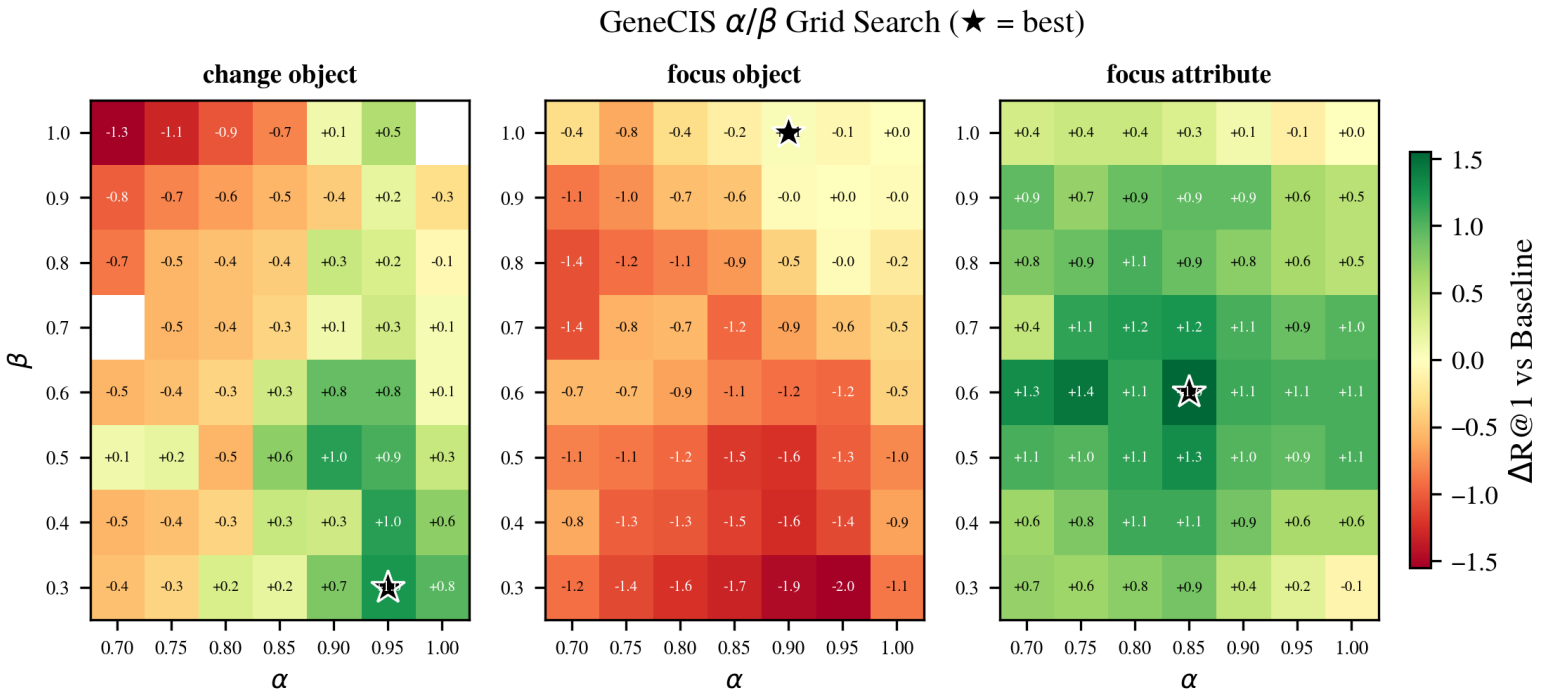

超参数含义

β: D_1 特征权重 (1→ 仅 D_1, 0→ 仅 D_2)
α: 文本信号 vs. 代理图信号
(1→ 仅文本 , 0→ 仅代理图)

GeneCIS 各子集最优 (α, β)

change_object	α=0.95	β=0.50	**+0.77**
focus_object	α=0.80	β=1.00	**+0.82**
change_attr	(需重建 gallery)		**—**
focus_attr	α=1.00	β=0.60	**+1.05**

结论 :
- focus_object 需 高 β + 低 α (反向)
- 其他 3 子集偏 低 β + 高 α

→ 证明 task-adaptive 调参的必要性

05.2 消融 · 三个组件的独立贡献

Visual Proxy / V7 CoT / Ensemble 逐个对比基线

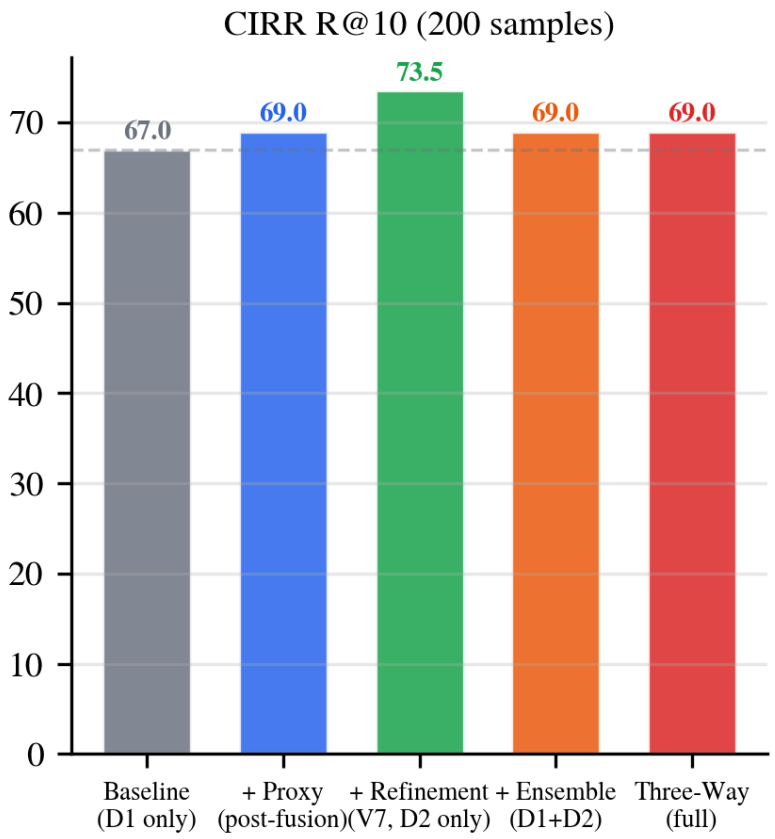

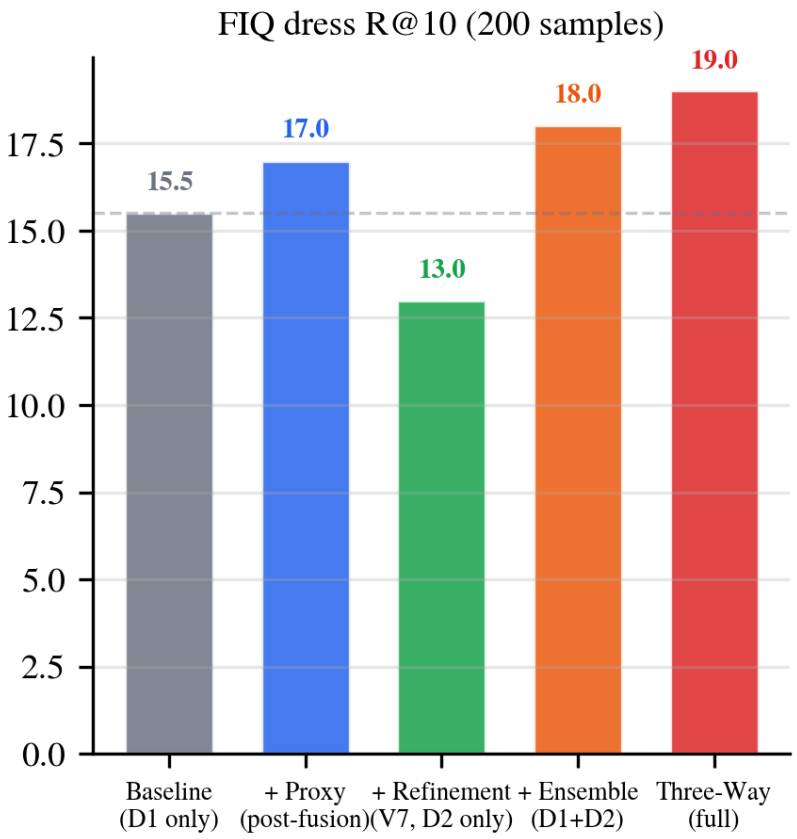

消融分析 (CIRR R@10)

Baseline (D1 only)	**67.0**
+ Visual Proxy	**69.5 (+2.5)**
+ V7 CoT (D1→D2)	**73.5 (+6.5)**
+ V7 + Proxy (无 Ens)	**70.5 (+3.5)**
Full (三路融合)	**68.7 (+1.7)***

* 牺牲 CIRR 单点峰值，换取 9 子集全正向

关键结论：
- V7 贡献最大 (+6.5)
- Proxy 与 Ensemble 协同使结果稳健
- 三者缺一不可

04.4 相对提升概览

9 个数据集主指标相对提升柱状图

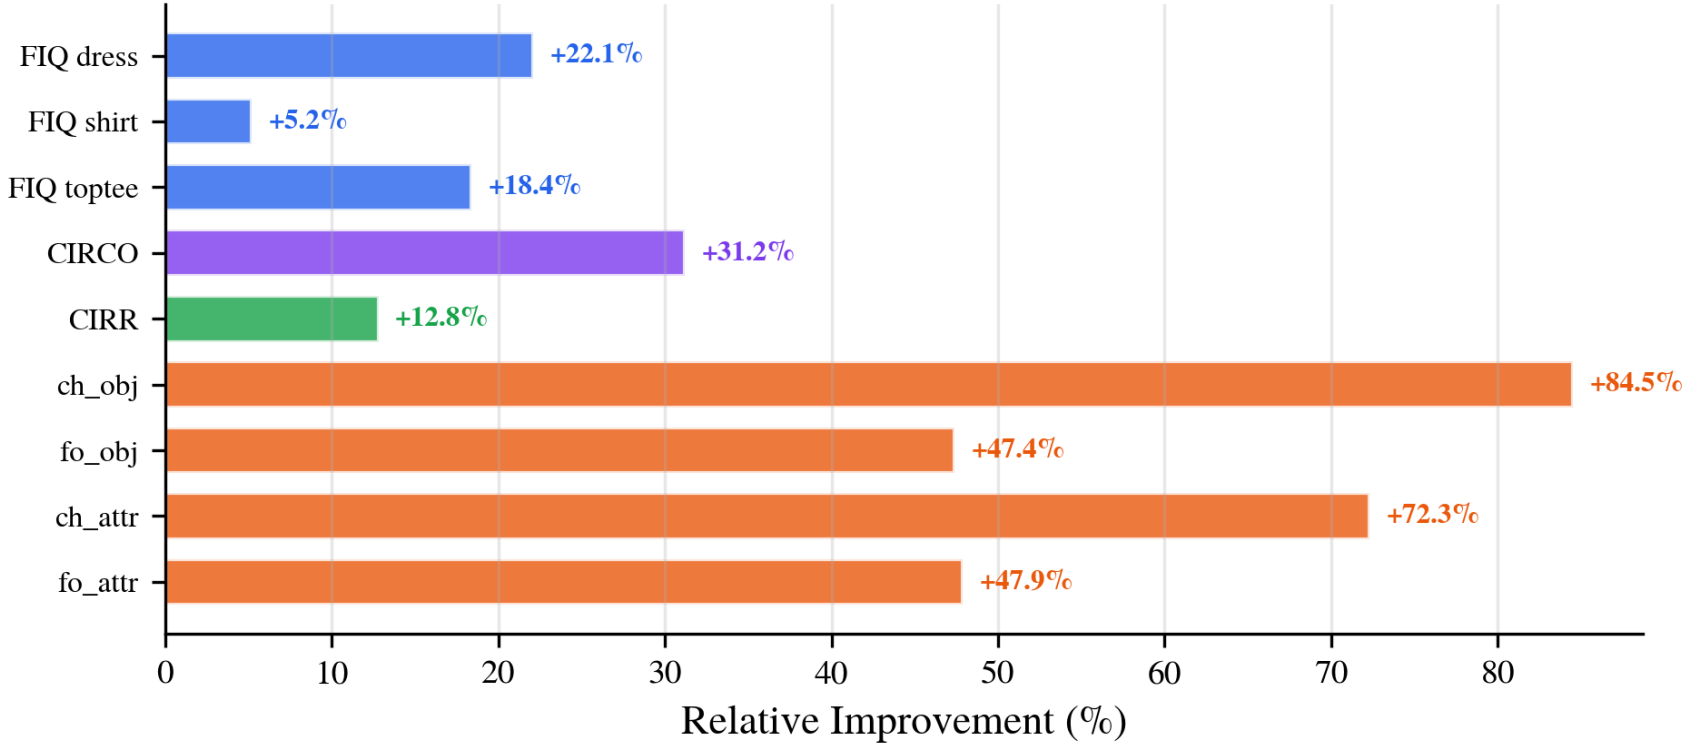

TOP 3 相对提升

1 **GeneCIS ch_obj** **+84.5%**

13.83 → 25.51

2 **GeneCIS ch_attr** **+72.3%**

12.65 → 21.79

3 **GeneCIS fo_attr** **+47.9%**

18.82 → 27.83

→ GeneCIS 受益最大
→ MLLM 推理 + proxy 校验 对细粒度属性 / 物体修改任务特别有效

C1 贡献

方法学

提出 三路融合 ZS-CIR 框架：Visual Proxy（图像信号）+ V7 Anti-Hallucination CoT（描述校验）+ Description Ensemble（特征空间兜底），首次系统性结合三种机制用于零样本 CIR

C2 贡献

Prompt 工程

通过 4 轮迭代，诊断并解决 “代理图既是参照又是幻觉源” 的核心矛盾，
提出 “诊断而非描述” 的设计原则，将 MLLM 从自由生成器降维为结构化校验器

C3 贡献

实验验证

在 9 个标准基准上完成全量实验，35/35 指标全部提升；
FashionIQ 相对提升 5~22%, CIRCO mAP 相对提升 31.2%, GeneCIS R@1 提升 47~85%

C4 贡献

工程与可复现

完整开源代码 / LaTeX 论文 / 配图代码 / 全量实验 JSON · 已上线 GitHub
提供 Qwen-VL + MiniMax 的低成本替代方案，成本 ≈ GPT-4o 方案的 1/10

06.2 局限性与未来工作

工程与学术两个维度的后续拓展

当前工作局限

- **推理成本**

  每条 query 需 2 次 MLLM 调用 + 1 次 T2I 调用，耗时约 15-25s，尚未满足实时检索需求

- **baseline 与原论文差距**

  MLLM 替换为 Qwen-VL 使 FIQ 绝对值下降 13pp，但改进幅度仍保持一致，方法本身不受影响

- **超参数依赖**

  α=0.9, β=0.7 在多数任务最优，但 GeneCIS focus_object 需反向，需 task-adaptive 调参

- **proxy 质量波动**

  T2I 模型对长描述 / 复杂场景 仍会生成低质代理图，部分样本 proxy 反而成为干扰

后续可拓展方向

- **F1 proxy 质量感知**

  用 CLIP 相似度评估 proxy 质量，动态调整 α

- **F2 蒸馏到小模型**

  将三路融合流程蒸馏成一个轻量 CLIP 投影头，做到 10ms 级在线检索

- **F3 迭代式 proxy 生成**

  多轮 “文本→图像→再推理” 循环，直到描述收敛

- **F4 跨模态评估框架**

  把 proxy 引入开放域 CIR benchmark 设计，提供更严格的 ZS-CIR 评估口径

核心数字速查 · Answer Cheat-Sheet

任务与设置

数据集总数	**9 个**
FashionIQ 子集	**dress / shirt / toptee**
CIRCO / CIRR	**220 / 4181 queries**
GeneCIS 子集	**ch/fc × obj/attr**
查询总数	**~ 18 K**
最大 gallery	**CIRCO 123 K**
CLIP backbone	**ViT-L/14**
MLLM	**Qwen-VL-Max**
T2I	**MiniMax image-01**
默认 α / β	**0.90 / 0.70**

主要结果 (baseline → 3-way)

FIQ dress R@10	**15.80 → 19.29 (+22%)**
FIQ shirt R@10	**26.00 → 27.35 (+5%)**
FIQ toptee R@10	**23.09 → 27.35 (+18%)**
CIRCO mAP@10	**16.21 → 21.26 (+31%)**
CIRR R@1	**22.96 → 25.90 (+13%)**
GeneCIS ch_obj R@1	**13.83 → 25.51 (+85%)**
GeneCIS fc_obj R@1	**16.02 → 23.62 (+47%)**
GeneCIS ch_attr R@1	**12.65 → 21.79 (+72%)**
GeneCIS fc_attr R@1	**18.82 → 27.83 (+48%)**
总指标	**35 / 35 正向**

规模 · prompt 迭代 4 轮 | API 调用 ~ 15 万次 | 总成本 ≈ 140 元

Thanks for Your Attention

恳请各位老师批评指正

GitHub 开源：

https://github.com/Haookok/osrcir-threeway-fusion

杨浩铭 · 同济大学 · 计算机科学与技术

2026 届本科毕业设计