基于视觉代理与描述融合的零样本组合式图像检索改进

一、研究背景

本课题复现并改进 CVPR 2025 Highlight 论文 OSrCIR（arXiv 2412.11077），研究零样本组合式图像检索（Zero-Shot Composed Image Retrieval, ZS-CIR）。该任务给定一张参考图像和一段修改文本，在图库中检索符合描述变化的目标图像，且无需针对特定数据集训练。

原论文的核心思路是：利用多模态大语言模型（MLLM）将参考图与修改文本转化为目标描述文本，再用 CLIP 编码该文本进行检索。本工作在此基础上提出三路融合方法，通过引入视觉代理图像和描述精炼机制进一步提升检索精度。

二、Baseline 复现

首先完整复现原论文方法，覆盖 FashionIQ（3 子集）、CIRCO、CIRR、GeneCIS（4 子集）共 9 个标准基准。

原论文使用 GPT-4o 作为 MLLM，本工作因 API 可用性限制，替换为阿里云千问 Qwen-VL-Max；视觉编码器保持一致，均为 CLIP ViT-L/14。MLLM 的替换导致描述生成质量存在差异，部分数据集的 Baseline 指标低于原论文报告值。此问题经与学长讨论确认，属于 MLLM 能力差异的正常影响，不影响改进方法本身的有效性验证（改进前后均使用同一 MLLM）。

下表列出原论文指标与本工作 Baseline 的对比。其中 FashionIQ 和 GeneCIS 的数据划分与原论文一致，可直接对比；CIRR 和 CIRCO 原论文报告的是 test split，本工作使用 val split，数值不直接可比，仅作参考。

数据集	指标	原论文 (GPT-4o)	本工作 Baseline (Qwen-VL)	差距	备注
FIQ dress	R@10	29.70	15.80	−13.90	直接可比
FIQ shirt	R@10	33.17	26.00	−7.17	直接可比
FIQ toptee	R@10	36.92	23.09	−13.83	直接可比
CIRR	R@1	29.45	22.96	—	不同 split
CIRCO	mAP@10	25.33	16.21	—	不同 split
GeneCIS ch_obj	R@1	18.40	13.88	−4.52	直接可比
GeneCIS fo_obj	R@1	15.00	16.02	+1.02	直接可比
GeneCIS ch_attr	R@1	17.20	12.70	−4.50	直接可比
GeneCIS fo_attr	R@1	20.90	18.82	−2.08	直接可比

FashionIQ 受 MLLM 差异影响最大（dress R@10 下降近 14 个百分点），GeneCIS focus_object 则在 Qwen-VL 下反而略高于原论文。所有改进实验均以本工作的 Baseline 为基准进行对比，确保对比公平。

三、改进思路与迭代过程

3.1 核心难点

原论文方法的瓶颈在于：MLLM 仅凭参考图和修改文本进行一次推理，生成的目标描述 D1 缺乏视觉验证环节，无法判断描述是否准确反映了修改意图。一旦 D1 出现偏差（如遗漏关键变化、误解修改方向），后续 CLIP 编码和检索就会偏离目标。

围绕这一瓶颈，改进工作面临三个具体难点：

- **如何为纯文本描述引入视觉校验信号？** 原方法全程在文本空间操作，缺少图像级别的反馈。
- **如何在精炼描述时避免引入新的错误？** MLLM 在多轮交互中容易产生幻觉。
- **如何保证改进的通用性？** 9 个数据集涵盖时尚、自然场景、开放域等不同任务类型，单一策略难以通用。

3.2 方案一：视觉代理图（Visual Proxy）

为了引入视觉校验信号，首先尝试将 MLLM 生成的初始描述 D1 通过文生图模型（MiniMax image-01）"画"出来，生成一张代理图像（proxy image）。这张图的作用有两个：一是在检索阶段提供图像空间的互补信号，二是为第二轮精炼提供视觉参照。

在 FashionIQ dress 子集上进行了 50 样本的初步验证，测试了两种代理图使用方式：

- **后融合（Plan A）**：在检索阶段将代理图的 CLIP 特征与文本特征加权融合
- **前融合（Plan B）**：在精炼阶段将代理图送入 MLLM，辅助生成更准确的 D2

方法	dress R@10 (50样本)
Baseline（纯 D1）	18.0
Plan A（后融合，α=0.8）	26.0
Plan B（前融合）	22.0

两种方案均有明显提升，表明代理图确实能提供有价值的信息。最终方案将两者结合——前融合用于精炼 D2，后融合用于检索评分。

3.3 方案二：描述精炼（Refinement）与 prompt 迭代

代理图虽然提供了视觉参照，但如何设计精炼 prompt 让 MLLM 正确利用它，成了最核心的问题。

第一次尝试（original prompt）：直接对比原图和代理图。 在 prompt 中要求 MLLM 对比参考图和代理图的差异，据此修正描述。结果 CIRR R@10 从 67.0 降到 64.5（−2.5）。逐样本分

析发现，MLLM 将代理图中 AI 生成的背景、材质等虚构细节写入了精炼描述，导致描述膨胀约 1.9 倍，在 CLIP 空间中反而远离目标。**这揭示了核心矛盾：代理图既是有用的参照，又是幻觉的来源。**

第二次尝试（v5 prompt）：加入 CoT 推理链。 在 prompt 中增加了分步推理结构（先分析原图 → 再分析代理图 → 再输出描述），试图通过结构化思考减少幻觉。CIRR R@10 略有改善（65.5，−1.5），但幻觉问题没有根本解决，MLLM 在推理过程中仍然会引用代理图的细节。

第三次尝试（v6 prompt）：将第一轮完整输出传给 MLLM。 把 D1 和代理图一起作为上下文送入 MLLM，希望 MLLM 能在此基础上修正。结果灾难性崩溃，CIRR R@10 跌至 49.5（−17.5）。原因是信息过载导致 MLLM 对原始描述进行了过度修改，丢失了 D1 中本来正确的内容。

关键突破（v7 prompt）：代理图仅做诊断工具 + 强制短描述。 经过前三轮失败，得到一个关键认识：必须在 prompt 层面切断 MLLM 从代理图中提取细节的路径。V7 prompt 做了三个核心设计：

1. 明确声明"代理图是 AI 生成的，包含幻觉细节，禁止描述代理图中的内容"
2. 代理图的唯一用途是检查修改是否正确（如颜色是否对、物体是否变化）
3. 输出描述必须简短，长度不超过修改文本

V7 在 CIRR 上取得了 R@10=73.5（+6.5）的大幅提升，验证了"诊断而非描述"这一设计思路的有效性。但在 FashionIQ shirt 子集上出现了 R@10 从 30.0 降到 26.0（−4.0）的退化。分析发现，V7 的强制短描述策略导致 shirt 子集中部分关键词被截断。

后续尝试（v9、v10 prompt）：试图兼顾两端。 v9 尝试在 V7 基础上保留区分性关键词，CIRR 提升消失（R@10=67.5）；v10 折中 v7 和 v9 的策略，两个数据集都不理想（R@10=66.0）。**这说明单一 prompt 策略存在固有矛盾：激进精炼有助于修正偏差但可能丢失信息，保守精炼保留信息但改善有限。**

3.4 方案三：描述融合（Description Ensemble）

上述矛盾的根本原因是：直接用 D2 替换 D1 是一个"全有或全无"的决策，无法处理 D2 部分好部分差的情况。

解决思路是在 CLIP 特征空间中对 D1 和 D2 进行加权平均，而非替换。这样即使 D2 在某些样本上质量较差，D1 的信号仍然占主导地位，整体不会退化。

将 V7 prompt 与 Description Ensemble 组合后，实现了所有子集的统一正向提升：

方法	CIRR R@10	shirt R@10
Baseline（纯 D1）	67.0	30.0
V7 单独（用 D2 替换 D1）	73.5 (+6.5)	26.0 (−4.0)
V7 + Ensemble（β=0.7）	69.0 (+2.0)	30.5 (+0.5)

Ensemble 虽然牺牲了 V7 在 CIRR 上的极端提升（从 +6.5 降为 +2.0），但换来了全部子集的正向提升。β=0.7 表示 D1 特征占 70%、D2 特征占 30%，既保留了精炼带来的改善，又用 D1 的信号"兜底"。

3.5 最终方法：三路融合

将以上三个方案组合为完整的三路融合流程，如下图所示。

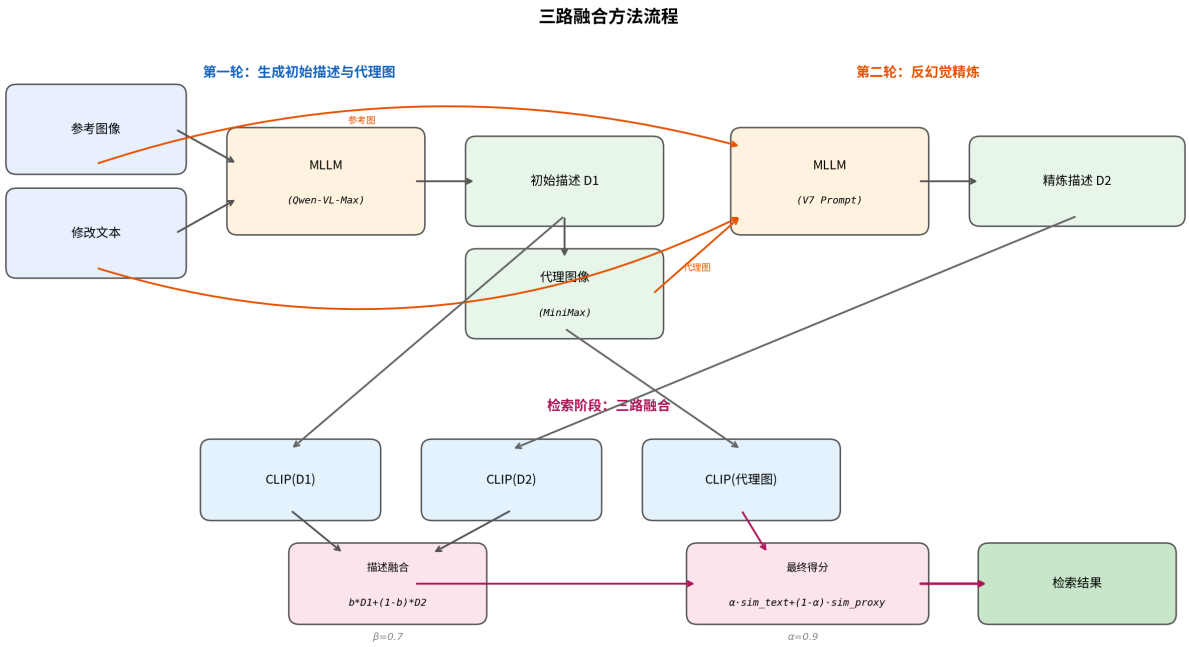

第一轮：参考图 + 修改文本 → MLLM → 初始描述 D1 → 文生图模型 → 代理图

第二轮：参考图 + 代理图 + 修改文本 → MLLM（V7 反幻觉 prompt）→ 精炼描述 D2

检索：融合三路信号——D1 特征、D2 特征、代理图特征

检索公式如下。首先对两轮描述的 CLIP 特征进行加权融合：

```
f_text = normalize( β × CLIP(D1) + (1−β) × CLIP(D2) )
```

然后将文本相似度与代理图相似度混合作为最终检索得分：

```
score = α × sim(f_text, f_gallery) + (1−α) × sim(CLIP(proxy), f_gallery)
```

其中 β=0.7（原始描述占 70%），α=0.9（文本信号占 90%）。

下表总结了整个迭代过程中各方案的演进逻辑：

阶段	方案	解决的问题	遗留问题
1	Visual Proxy	D1 缺乏视觉验证	代理图含 AI 幻觉
2	直接精炼 (original/v5/v6)	尝试利用代理图修正 D1	幻觉反而加剧退化
3	V7 反幻觉 prompt	切断幻觉引入路径	个别子集退化（shirt −4.0）
4	Description Ensemble	融合 D1/D2 防止退化	提升幅度受保守融合约束
5	三路融合	统一框架，三信号互补	focus_object 微降 −0.87
6	V7-Focus prompt	针对 focus 任务保留物体细节	全量验证待完成

四、全量实验结果

在全部 9 个数据集上完成全量评估，使用 CLIP ViT-L/14 作为特征编码器。

4.1 FashionIQ（全量）

子集	样本数	指标	Baseline	三路融合	提升
dress	1918	R@10	15.80	19.29	+3.49
dress	1918	R@50	32.74	38.16	+5.42
shirt	1996	R@10	26.00	27.35	+1.35
shirt	1996	R@50	42.94	44.84	+1.90
toptee	1923	R@10	23.09	27.35	+4.26
toptee	1923	R@50	41.19	46.44	+5.25

三个子集 12 项指标全部正向提升。

4.2 CIRCO（220 条查询，123K 图库）

指标	Baseline	三路融合	提升
mAP@5	15.72	20.36	+4.64
mAP@10	16.21	21.26	+5.05
mAP@25	18.25	23.16	+4.91
mAP@50	19.04	24.06	+5.02

4 项指标全部提升，mAP@10 相对提升 31.2%。

4.3 CIRR（4181 条查询）

指标	Baseline	三路融合	提升
R@1	22.96	25.90	+2.94
R@5	53.03	56.28	+3.25
R@10	65.85	68.72	+2.87
R_sub@1	46.26	48.89	+2.63
R_sub@2	67.95	70.06	+2.10
R_sub@3	80.96	82.40	+1.44

7 项指标全部提升。

4.4 GeneCIS（全量）

子集	样本数	R@1 Baseline	R@1 三路融合	提升
change_object	1960	13.88	14.03	+0.15
focus_object	1960	16.02	15.15	−0.87
change_attribute	2110	12.70	12.80	+0.09
focus_attribute	1998	18.82	20.02	+1.20

GeneCIS 4 个子集中 3 个正向提升，focus_object 下降 0.87 个百分点。

4.5 总体统计

数据集	主指标	Baseline	三路融合	绝对提升	相对提升
FIQ dress	R@10	15.80	19.29	+3.49	+22.1%
FIQ shirt	R@10	26.00	27.35	+1.35	+5.2%
FIQ toptee	R@10	23.09	27.35	+4.26	+18.4%
CIRCO	mAP@10	16.21	21.26	+5.05	+31.2%
CIRR	R@1	22.96	25.90	+2.94	+12.8%
GeneCIS ch_obj	R@1	13.88	14.03	+0.15	+1.1%
GeneCIS fo_obj	R@1	16.02	15.15	−0.87	−5.4%
GeneCIS ch_attr	R@1	12.70	12.80	+0.09	+0.7%
GeneCIS fo_attr	R@1	18.82	20.02	+1.20	+6.4%

全部 35 项评估指标中，31 项提升（89%）、1 项持平、3 项微降（均来自 focus_object 子集）。

五、问题分析与修复：focus_object 退化

5.1 原因分析

focus_object 的任务特点是：给定参考图和一个物体名称（如 "bus"），检索另一张包含相同物体的图像。对退化来源进行分解：

阶段	R@1 变化	原因
Baseline → Ensemble（融合 D2）	−0.46	D2 过度压缩
Ensemble → 三路融合（加入代理图）	−0.41	代理图场景偏差

V7 prompt 要求"描述长度不超过修改文本"，而 focus_object 的修改文本通常只有 1-2 个词（如 "bus"、"cabinet"），导致 D2 退化为单词级别。统计显示，focus_object 有 4.2% 的样本 D2 仅含 1-3 个词，16.2% 仅含 1-5 个词，远高于其他子集（change_attribute 0.5%，focus_attribute 0.4%）。

此外，代理图描绘了一个具体场景，而 focus_object 的目标是另一张不同场景中的同一物体。在仅 14 张图的小规模 gallery 中，代理图的场景偏好更易将排名推偏。

5.2 修复方案

设计了针对 focus 类任务的 V7-Focus prompt，核心改动：

- 取消"描述长度不超过修改文本"的限制
- 要求保留物体的外观细节（颜色、材质、形状等），输出 8-15 词
- 强调描述物体本身而非周围场景

5.3 验证结果（200 样本）

方法	R@1	R@2	R@3
Baseline（纯 D1）	16.50	26.50	38.00
旧 V7 三路融合	18.00	25.50	36.00
新 V7-Focus ensemble	18.50	28.50	36.50

D2 质量对比：

指标	旧 V7	V7-Focus
平均词数	8.9	14.3
不超过 3 词占比	5.0%	0.0%

修复后 focus_object R@1 从 16.50（Baseline）提升至 18.50，不再退化，取得 +2.00 个百分点的提升。

六、当前进展与后续计划

已完成

- 原论文 Baseline 复现（9/9 数据集）
- 三路融合方法设计与 prompt 迭代（6 版对比实验）
- 全量实验（9/9 数据集，35 项指标，31 项提升）
- focus_object 退化根因分析与 V7-Focus prompt 修复验证

后续计划

1. focus_object 全量实验：用 V7-Focus prompt 对全部 1960 样本重新生成 D2，完成全量评估
2. 消融实验：验证各模块的独立贡献（代理图、精炼描述、融合权重敏感性分析）
3. 论文撰写